




1、最优化就是模型得到最优解，也就是最优点和最优值。那么先要理解局部最优、全局最优。



2、如何求解得到这个最优解。用导数、方向导数和梯度的概

念，同时需要借助 matlab 的图形功能（需要同学们自己加强）。

**例子 1：**  $y = x.^2$ ，图形如下：



```
x=linspace(-18,18);%生成行向量，即生成横坐标的值
```

```
y=x.^2;%定义函数，得到纵坐标的值
```

```
plot(x,y);%画图，根据两个坐标值，画出图形
```

---

根据图形，可以看出最优解是  $x = 0$ ，可以用 matlab 根据导数的概念进行求解，如下：

```
syms x;%定义变量
```


```
y=x.^2;%定义函数
```

```
s=diff(y);%求导 注：differential coefficient 导数
```

```
a=solve(s,'x');%求根 或者直接 a=solve(s)?
```

```
b=double(a);%转换数值
```

**例子 2：**  $y = (x_1-1).^2 + (x_2+2).^2$ ，图形如下：



```
[X1, X2] = meshgrid(-4:.1:4); %生成笛卡尔坐标网格
Y = (X1-1).^2 + (X2+2).^2; % Y = sqrt((X1-1).^2 + (X2+2).^2);
figure;%创建图形窗口，这样就可以生成很多个图形
meshc(X1,X2,Y);%生成 mesh 图和 contour 图（等高线）
```

利用导数的知识，求导得到最优解，如下：

```
syms y x1 x2; %定义变量
y=(x1-1).^2+(x2+2).^2; %定义函数
s=[diff(y,x1),diff(y,x2)];%分别求导
[Sx,Sy]=solve(s(1),s(2));%求根
z=double([Sx,Sy])%数值化
```

或者，采用梯度的函数，如下：

```
syms y x1 x2; %定义变量
```



```
y=(x1-1).^2+(x2+2).^2;%定义函数
```

```
grad_ff=gradient(y,[x1,x2]);%直接用梯度函数求解
```

```
[Sx,Sy]=solve(grad_ff);%求根
```

```
z=double([Sx,Sy]);%数值化
```

3、那什么是梯度呢？梯度的概念，先说一下方向导数的概念，如图：



梯度就是在 360 度的方向中，某一个方向的方向导数。

**问题:**函数在点  $P$  沿哪一方向增加的速度最快?

**定义** 设函数  $z = f(x, y)$  在平面区域  $D$  内具有一阶连续偏导数，则对于每一点  $P(x, y) \in D$ ，都可定出一个向量  $\frac{\partial f}{\partial x} \vec{i} + \frac{\partial f}{\partial y} \vec{j}$ ，这向量称为函数  $z = f(x, y)$  在点  $P(x, y)$  的**梯度**，记为

$$\overrightarrow{\text{grad}} f(x, y) = \frac{\partial f}{\partial x} \vec{i} + \frac{\partial f}{\partial y} \vec{j}.$$

看例子：

**例 2** 求函数  $f(x, y) = x^2 - xy + y^2$  在点  $(1, 1)$  沿与  $x$  轴方向夹角为  $\alpha$  的方向射线  $\vec{r}$  的方向导数. 并问在怎样的方向上此方向导数有

(1) 最大值； (2) 最小值； (3) 等于零？

用 matlab 求解函数在某个具体点的梯度，代码如下：

```
syms z x y; %定义变量
```

```
z=x.^2-x*y+y.^2; %定义函数
```

```
grad_ff=gradient(z,[x,y]);%直接用梯度函数求解
```

```
grad2 = subs(grad_ff,{x,y},{1,1})%用 (1, 1) 求出具体值
```

最后得到梯度为  $(1, 1)$ ，那就是 45 度的方向。就是说，45 度的方向，导数的值最大，45 的反方向就是  $45+180$ ，是负梯度方向，与这个方向垂直的方向  $45+90$  和  $45+270$  是导数值为 0。



**例4** 求函数  $u = x^2 + 2y^2 + 3z^2 + 3x - 2y$  在点  $(1, 1, 2)$  处的梯度，并问在 哪些点处梯度为零向量？

**解** 由梯度计算公式得


$$\begin{aligned}\overrightarrow{\text{grad}}u(x, y, z) &= \frac{\partial u}{\partial x} \vec{i} + \frac{\partial u}{\partial y} \vec{j} + \frac{\partial u}{\partial z} \vec{k} \\ &= (2x + 3)\vec{i} + (4y - 2)\vec{j} + 6z \vec{k},\end{aligned}$$


故  $\overrightarrow{\text{grad}}u(1, 1, 2) = 5\vec{i} + 2\vec{j} + 12\vec{k}.$

在  $P_0(-\frac{3}{2}, \frac{1}{2}, 0)$  处梯度为零向量.

可以用上面的代码验证这道题对不对。

从上往下看，梯度和等高线的关系，如下：





**结论:**  $\nabla f(x_0)$  与等值面在点  $x_0$  处的切平面垂直, 所以  $\nabla f(x_0)$  是等值面  $S$  在点  $x_0$  处的一个法线方向向量.

**对于  $n = 2$  的情形:**


$$\nabla f(x_0, y_0) = \{f'_x(x_0, y_0), f'_y(x_0, y_0)\}$$

是函数  $f(x, y)$  过点  $(x_0, y_0)$  的等值线


$$f(x, y) = f(x_0, y_0)$$

在点  $(x_0, y_0)$  处的一个法线方向向量.


在该点处, 它与等值线的切线垂直.



总结, 看图:



4、除了用“梯度”的概念（梯度为0）去求解最优值，还可以用一种“迭代”的思路求解最优解，或者说是“迭代算法”。看图如下：




这种迭代的算法，我们可以叫做“下降迭代算法”。看图：



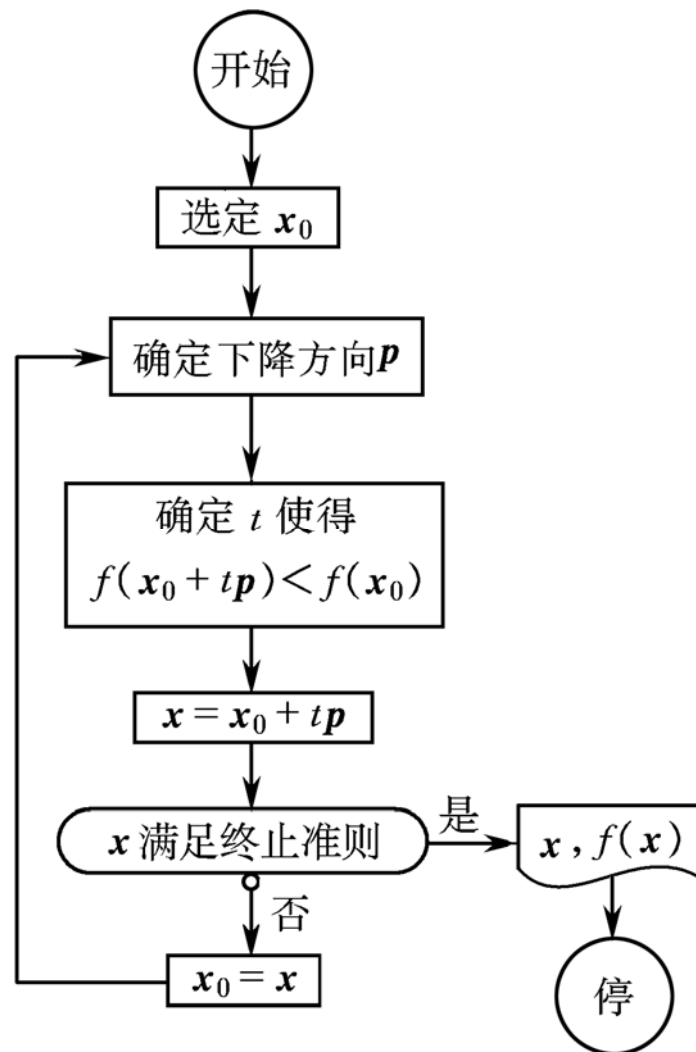
在集合  $X$  上的迭代算法是指：开始，选定一个初始点  $x_0 \in X$ ，置  $k=0$ 。然后按某种规则  $A$ ，把第  $k$  次迭代点  $x_k$  映射为新的点  $x_{k+1} \in X$ ，记为  $x_{k+1} = A(x_k)$ ，并置  $k = k+1$ 。这称为完成了第  $k+1$  次迭代。这个过程无限地进行下去，就会产生一个点列  $\{x_k\}$ 。因此，规则  $A$  称为算法。

若点列  $\{x_k\}$  收敛于  $X$ ，则称算法  $A$  在  $X$  上是收敛的；否则，称算法  $A$  在  $X$  上是发散的。特别地，当  $X$  是最优化问题 (1.6) 的容许集时，若除满足计算终止准则的迭代点外，对于每个  $k$ ，都有  $f(x_{k+1}^V) < f(x_k^V)$ ，则称  $A$  为下降迭代

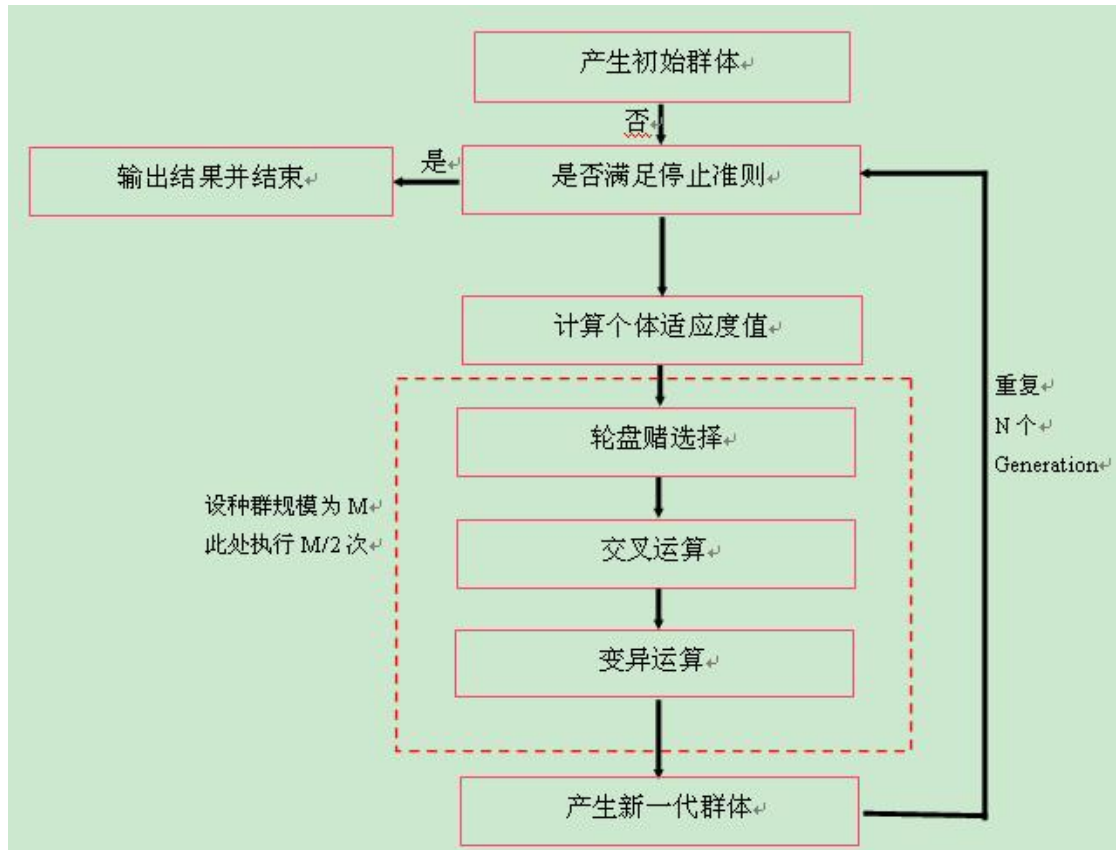
现在问题就是，最优化学习的主要内容就是这种算法，因此要学习不同的算法，可以让初始点迭代到最优点。其中有一种典型的指导规则，就是利用“梯度下降”的概念引导迭代，看图：



算法流程图为：



那还有一种指导规则，叫做“启发式规则”（会利用到概率），用某种知识去引导从“初始点”逼近“最优点”。这里面的典型算法就是 GA，利用进化的知识去模拟迭代算法，它们也是一种迭代算法，如下图。



5、泰勒公式展开，这是一个有用的公式，看图：

$$\begin{aligned}
 f(x) = & f(x_0) + f'(x_0)(x - x_0) \\
 & + \frac{f''(x_0)}{2}(x - x_0)^2 + \dots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n \\
 & + \frac{f^{(n+1)}(x_0 + \theta(x - x_0))}{(n+1)!}(x - x_0)^{n+1} \quad (0 < \theta < 1).
 \end{aligned}$$

意义：可用  $n$  次多项式来近似表达函数  $f(x)$ ，且误差是当  $x \rightarrow x_0$  时比  $(x - x_0)^n$  高阶的无穷小。

## 一、利用导数作近似计算

### 1. 近似计算

是用计算方法得到一定精度的计算结果.

若  $y = f(x)$  在  $x_0$  可微, 则有

$$\Delta y = f'(x_0)\Delta x + o(\Delta x), \quad (\Delta x \rightarrow 0)$$

于是  $\Delta y \approx f'(x_0)\Delta x$ , ( $|\Delta x|$  充分小).

又  $\Delta y = f(x_0 + \Delta x) - f(x_0)$ ,

故  $f(x_0 + \Delta x) \approx f(x_0) + f'(x_0)\Delta x$ , ( $|\Delta x|$  充分小).

